

Análise de Evasão Escolar no Brasil com Integração de Dados Educacionais e Socioeconômicos

1. Introdução

A evasão escolar é um dos principais desafios da educação brasileira, impactando diretamente o desenvolvimento social e econômico do país. Fatores como renda, infraestrutura escolar, localização geográfica e desempenho acadêmico influenciam significativamente a permanência dos alunos na escola.

Este projeto tem como objetivo construir uma solução de análise de dados capaz de identificar padrões e relações entre evasão escolar e variáveis socioeconômicas, utilizando bases oficiais do governo brasileiro.

Objetivos específicos:

- Identificar relações entre evasão escolar e renda média
- Comparar indicadores entre regiões (Norte, Nordeste, etc.)
- Avaliar diferenças entre ensino público e privado
- Analisar impacto da localização (urbana vs rural)
- Integrar múltiplas bases de dados educacionais

3. Fontes de Dados

O projeto utiliza dados oficiais de instituições brasileiras:

IBGE

- PNAD Contínua (Educação)
- Indicadores socioeconômicos
- Renda média por região

INEP (MEC)

- Indicadores educacionais
- Taxas de abandono, reprovação e aprovação
- Censo escolar

Bases utilizadas no projeto:

- Abandono escolar + renda média (2013–2023)
- Censo Escolar (2024 e 2025)
- Indicadores educacionais INEP
- Taxas de rendimento escolar

4. Arquitetura do Projeto

O pipeline de dados segue o modelo ETL (Extract, Transform, Load):

Fontes de dados (CSV, IBGE, INEP)

↓

Ingestão (Python / Pandas)

↓

Tratamento e limpeza

↓

Carga em banco de dados (MySQL)

↓

Orquestração (Apache Airflow)

↓

Análise e visualização

5. Tecnologias Utilizadas

- **Python (Pandas)** → tratamento de dados
- **MySQL** → armazenamento
- **Apache Airflow** → orquestração de pipelines
- **CSV (INEP / IBGE)** → fontes de dados
- (opcional) Power BI / Streamlit → visualização

6. Modelagem de Dados

O projeto utiliza um modelo relacional com integração entre múltiplas tabelas:

Tabelas principais:

- indicadores_completo
- censo_escolar
- indicadores_completos
- rendimento_escolar

Chaves de integração:

- Ano
- Região / UF
- Localização (urbana/rural)

★ Modelo ideal (Data Warehouse)

Tabela Fato:

- indicadores de evasão, renda e desempenho

Dimensões:

- localização
- dependência administrativa
- tipo de ensino

7. Pipeline de Dados (ETL)

O pipeline realiza:

☒ Extração

- leitura de arquivos CSV
- múltiplas fontes

☒ Transformação

- padronização de colunas
- tratamento de valores nulos
- conversão de tipos

☒ Carga

- inserção em banco MySQL
- uso de `executemany` para performance
- execução automatizada via Airflow

8. Orquestração com Airflow

As cargas são organizadas em DAGs:

 Pipeline principal:

Censo Escolar → Indicadores → INEP

- ☒ Execução automática
- ☒ Controle de erros
- ☒ Reprocessamento

9. Análises Possíveis

Com os dados integrados, é possível realizar análises como:

 Relação evasão × renda

- regiões com menor renda apresentam maior evasão

 Público vs privado

- escolas públicas apresentam maiores taxas de abandono

 Urbano vs rural

- áreas rurais possuem maior evasão

 Evolução temporal

- análise de tendência entre 2013 e 2023

10. Principais Insights

- A renda média tem forte correlação com a evasão escolar
- O ensino público apresenta maior vulnerabilidade
- Regiões Norte e Nordeste concentram maiores taxas de abandono
- A reprovação escolar impacta diretamente a evasão

☒ 11. Conclusão

O projeto demonstra como a integração de múltiplas bases de dados permite uma análise mais completa da evasão escolar no Brasil.

Além disso, mostra a aplicação prática de técnicas de engenharia de dados, incluindo:

- construção de pipelines
- integração de dados
- uso de Airflow
- modelagem de banco de dados